Многоклассовая классификация и калибровка вероятностей

Семинар 7

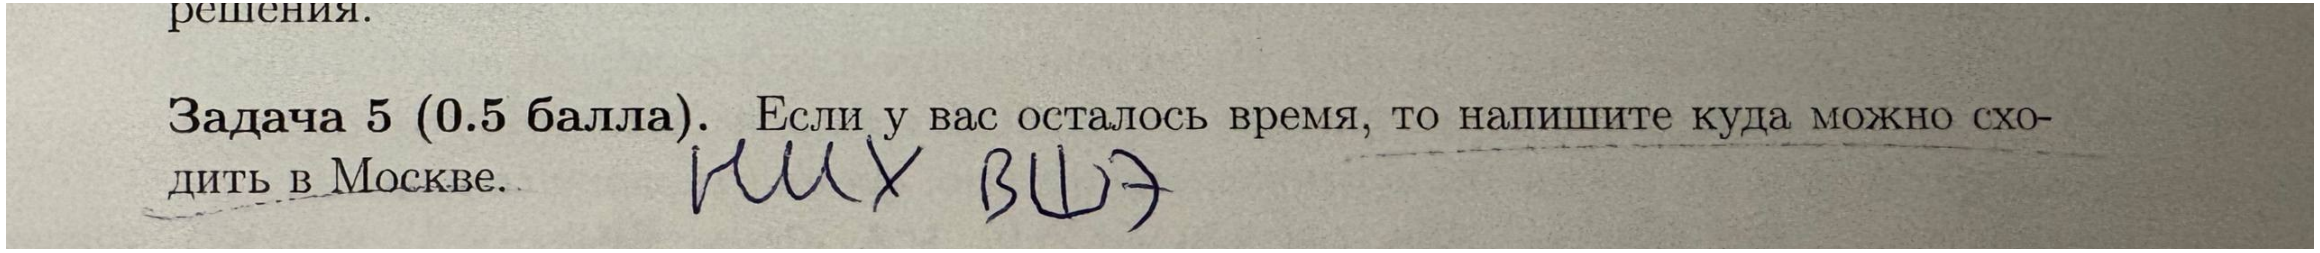
решения.

Задача 5 (0.5 балла). Если у вас осталось время, то напишите куда можно сходить в Москве.

КИХ ВШЭ

План

- Почему ROC-AUC "врет" при дисбалансе классов?
- Как модели прогнозируют “вероятности”?
- Многоклассовая классификация
- Метрики многоклассовой классификации
- Калибровка вероятностей

Почему ROC-AUC "врет" при дисбалансе классов?

ноутбук auc.ipynb

Как модели прогнозируют “вероятности”?

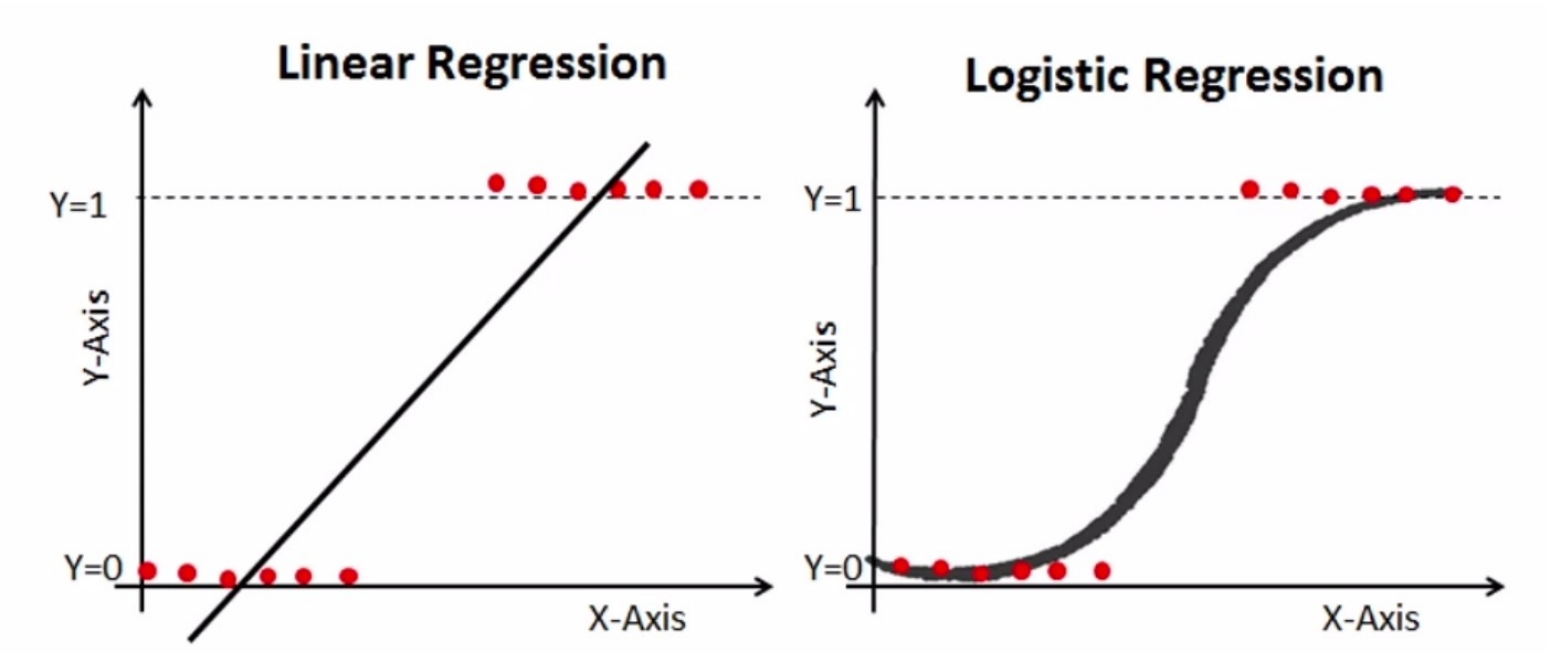

$$a(x) = < w, x >$$

$$a(x) = \sigma(< w, x >) = \frac{1}{1 + e^{-<w,x>}}$$

Многоклассовая классификация

Примеры:

- определения объекта на изображении
- определения тональности отзыва и многие другие
- предсказание следующего слова при генерации текста LLM
- и т.д

Многоклассовая классификация

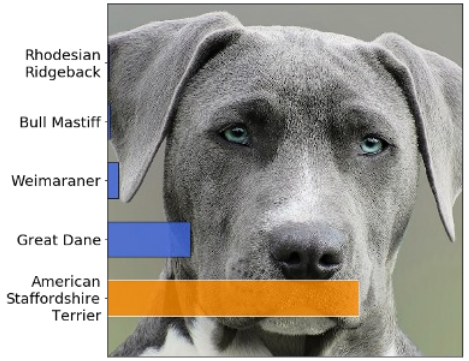

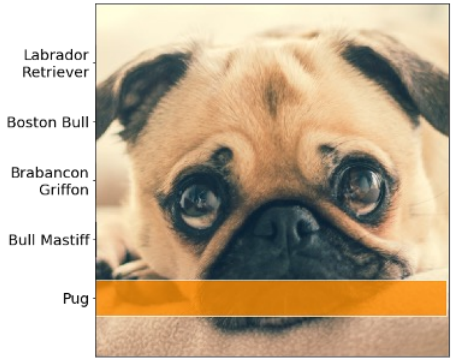

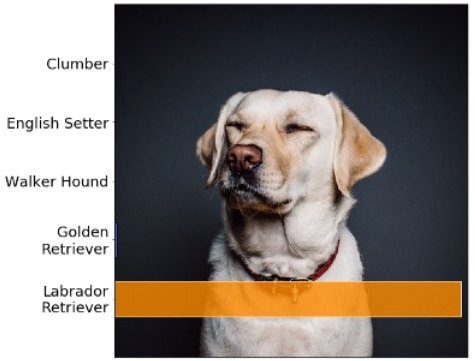

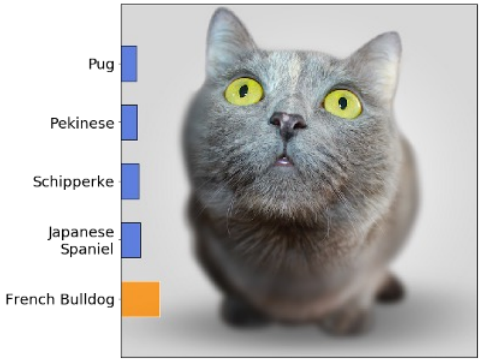

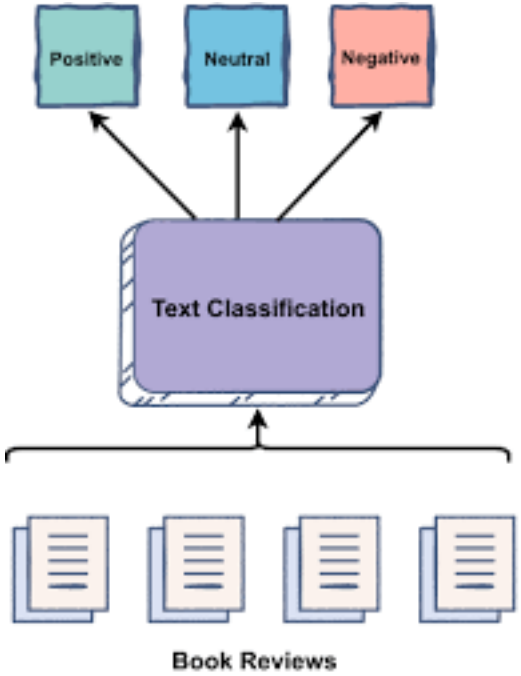

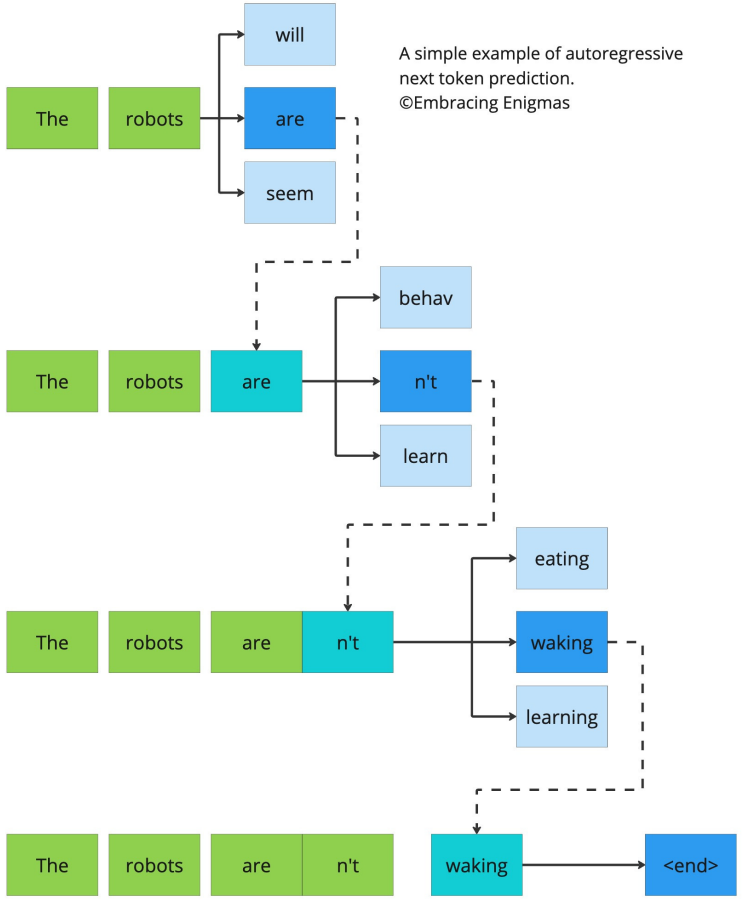

Многоклассовая классификация

Multiclass и **multilabel** классификации - это задачи разных типов.

- **Multiclass-классификация:** задача, в которой целевая переменная - это один из нескольких классов (где классов может быть больше, чем два)
- **Multilabel-классификация:** задача, в которой для каждого объекта предсказывается несколько меток (например, для фильма одновременно можно предсказать его жанр, год выпуска, язык фильма и так далее). Или же на картинке может быть изображен не один объект, а несколько - и наша задача определить классы всех объектов.

Multilabel-задачу можно свести к серии **multiclass**-задач.

Дальше мы будем обсуждать **multiclass**-классификацию, когда у каждого объекта одна метка.

Многоклассовая классификация

Сведение к бинарной классификации

Задачи многоклассовой (multiclass) классификации можно свести к серии бинарных задач. Два основных подхода называются **one-versus-one (OVO) и one-versus-rest (OVR)**.

One-versus-rest (OVR) подход
Сводим задачу к серии бинарных классификаторов, где i-й классификатор определяет, относится объект к классу i или не относится (два варианта, то есть бинарный классификатор).

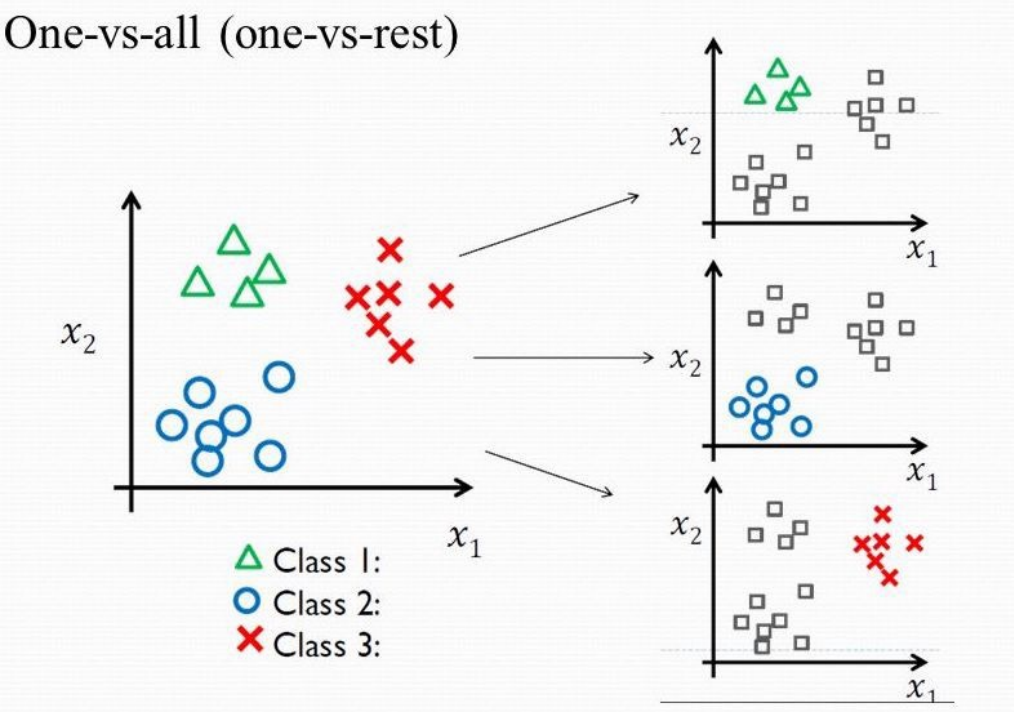

Многоклассовая классификация

Сведение к бинарной классификации

One-versus-one (OVO) подход

В этом подходе каждый бинарный классификатор пытается отличить, принадлежит объект классу i или классу j. Каждый такой классификатор обучается только на объектах i-го и j-го классов.

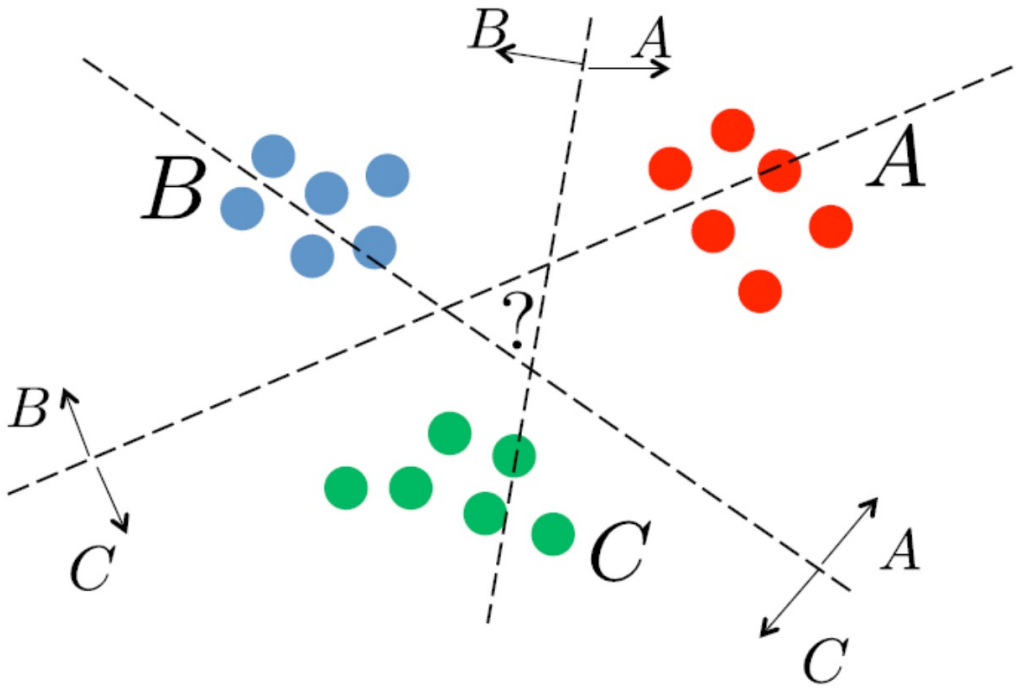

Многоклассовая классификация

Сведение к бинарной классификации

Нельзя в общем случае сказать, какой из подходов лучше. Однако у каждого из подходов есть особенности, связанные со скоростью обучения:

- Если мы выбираем подход **one-versus-all**, то при большом количестве объектов в данных обучение будет долгим, ведь нужно обучить несколько бинарных классификаторов на большом датасете. В случае one-versus-one каждый бинарный классификатор (с номером ij) обучается только на части датасета, состоящей из классов i и j.
- Если же классов в задаче много, то подход **one-versus-one** будет работать долго, так как он сводится к обучению бинарных классификаторов на каждой паре классов, то есть, если в задаче N классов, то необходимо обучить $N(N-1)/2$ бинарных классификаторов.

Многоклассовая классификация

LogReg для мультиклассовой классификации

	Binary classification	Multiclass classification
targets	{0,1}	{1,2, ..., C} или же [[1, 0, 0, 0, ..., 0] [0, 1, 0, 0, ..., 0] ... [0, 0, 0, 0, ..., 1]]
predictions (example)	0.8	[0.8, 0.1, 0.05, 0, ..., 0.05]

C – кол-во классов

Многоклассовая классификация

LogReg для мультиклассовой классификации

	Binary classification	Multiclass classification
activation function	sigmoid = $\frac{1}{1+e^{<w,x>}}$	sofmax = $\frac{e^{<w_i,x>}}{\sum_{j=1}^{C} e^{<w_j,x>}}$
loss	log-loss = $-ylog\big(a(x)\big) - (1-y)\log(1-a(x))$	cross entropy = $-\sum_i^C y_i \log(a(x)_i)$

C – кол-во классов

Многоклассовая классификация

LogReg для мультиклассовой классификации

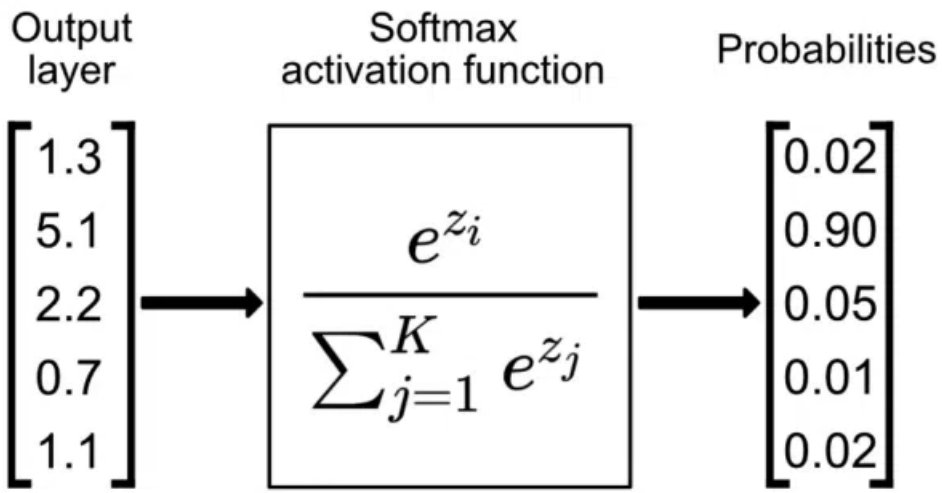

Метрики многоклассовой классификации

Accuracy - это доля правильных ответов модели, без изменений для любого количества классов

Как модифицируются метрики **precision**, **recall** и **f1-score** в многоклассовом случае?

Метрики многоклассовой классификации

Accuracy - это доля правильных ответов модели, без изменений для любого количества классов

Как модифицируются метрики **precision**, **recall** и **f1-score** в многоклассовом случае?

		True/Actual	
		Positive ( )	Negative
Predicted	Positive ( )	5 (TP)	1 (FP)
	Negative	2 (FN)	2 (TN)

$$precision = \frac{TP}{TP+FP}$$
$$recall = \frac{TP}{TP+FN}.$$

Метрики многоклассовой классификации

Существует несколько подходов:

- Микроусреднение (micro-average)
- Макроусреднение (macro-average)
- Взвешенное усреднение (weighted-average)

		True/Actual		
		Cat ( )	Fish ( )	Hen ( )
Predicted	Cat ( )	4	6	3
	Fish ( )	1	2	0
	Hen ( )	1	2	6

Метрики многоклассовой классификации

Макроусреднение (macro-average)

Вычисляем значение выбранной метрики для каждой бинарной ситуации (кошка/не кошка, рыба/не рыба, курица/не курица), а затем усредняем полученные числа

		True/Actual		
		Cat	Fish	Hen
Predicted	Cat	4	6	3
	Fish	1	2	0
	Hen	1	2	6

$$precision(cat) = \frac{TP}{TP+FP} = \frac{4}{4+6+3} = \frac{4}{13}$$

$$recall(cat) = \frac{TP}{TP+FN} = \frac{4}{4+1+1}$$

$$precision = \frac{precision(cat) + precision(fish) + precision(hen)}{3}$$

Аналогично вычисляется recall

Метрики многоклассовой классификации

Взвешенное усреднение (weighted-average)

Усредняем посчитанные для каждого класса метрики с весами, пропорциональными количеству объектов класса

		True/Actual		
		Cat ( )	Fish ( )	Hen ( )
Predicted	Cat ( )	4	6	3
	Fish ( )	1	2	0
	Hen ( )	1	2	6

$$precision = \frac{6}{25} \cdot precision(cat) + \frac{10}{25} \cdot precision(fish) + \frac{9}{25} \cdot precision(hen),$$

Аналогично вычисляется recall

Метрики многоклассовой классификации

Микроусреднение (micro-average)

Вычисляем значения TP, TN, FP, FN по всей матрице ошибок сразу, исходя из их определения. Затем по полученным числам вычисляем выбранные метрики

FP - это суммарное количество false positive-предсказаний.

Например, если cat предсказана как fish, то это false positive для fish.

Таким образом, FP - это сумма всех неверных предсказаний, то есть

FP=6+3+1+0+1+2=13

		True/Actual		
		Cat	Fish	Hen
Predicted	Cat	4	6	3
	Fish	1	2	0
	Hen	1	2	6

FN = FP -> precision = recall = f1

$$precision = \frac{12}{12+13} = \frac{12}{25}$$

Метрики многоклассовой классификации

	micro-avg	macro-avg	weighted-avg
Описание	Суммируем все «ошибки» и «попадания» в кучу, считаем общий результат	Считаем качество по каждому классу отдельно, потом берем среднее (все классы равны)	Считаем качество по каждому классу, но умножаем на «важность» (размер) класса
Работа с дисбалансом классов	Не учитывает дисбаланс, без разницы какое качество предсказаний для более редкого класса, важна картина в общем	Все классы равноценны, качество предсказаний для более редкого класса важно также как и качество для более частого класса	Учитывает вклад каждого класса, но пропорционально его размеру в данных
Когда выбрать	Важно общее качество на всех объектах. **Датасет сбалансирован**.	Важно качество для каждого класса. **Есть дисбаланс**, где малый класс критичен.	**Что-то среднее**, дает более реалистичную картину, чем микро (не завышает значение больших классов), но и не завышает значение малых классов, как макро.

Метрики многоклассовой классификации

Пример: решаем задачу **классификации животных** по фотографиям

Модель A		True/Actual		
		Cat	Fish	Hen/Chicken
Predicted	Cat	990	5	60
	Fish	10	890	10
	Hen/Chicken	0	5	30

	micro-avg	**macro-avg**	**weighted-avg**
f1	0.955	0.76	0.954

Метрики многоклассовой классификации

Пример: решаем задачу **классификации животных** по фотографиям

Модель B		True/Actual		
		Cat	Fish	Hen/Chicken
Predicted	Cat	940	30	10
	Fish	40	860	10
	Hen/Chicken	20	10	80

	micro-avg	**macro-avg**	**weighted-avg**
f1	0.94	0.896	0.941

Метрики многоклассовой классификации

micro-avg = accuracy

Калибровка вероятностей

Многие модели классификации умеют "предсказывать вероятности" классов. Это делается методом *predict_proba* из библиотеки *sklearn*

На самом деле предсказанные методом числа - это не всегда вероятности в общепринятом смысле. В большинстве случаев метод *predict_proba* выдает уверенности модели в том или ином классе, попадающие на отрезок [0;1]. Почему это не очень хорошо?

Калибровка вероятностей

Пример:

Пусть мы решаем задачу кредитного скоринга, и кроме класса (выдать клиенту кредит или нет) бизнес часто интересует вероятность, с которой клиент вернет кредит. Основываясь на этих вероятностях, бизнес будет принимать решение о способе взаимодействия с клиентом.

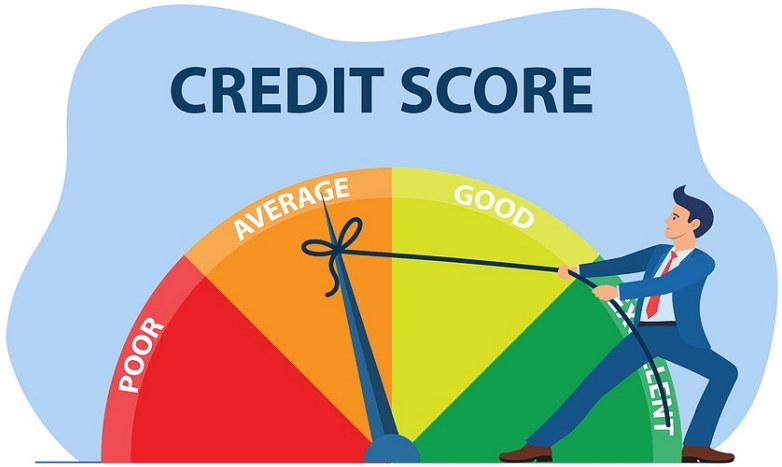

Калибровка вероятностей

Например, если клиент возвращает кредит с вероятностью 0.9, то это означает, что в 90 случаях из 100 клиенты с такими же характеристиками как наш вернут кредит. Так работает классическая вероятность.

Но большинство моделей после применения *predict_proba* могут выдать число, отличное от 0.9 - это будет уверенность модели в классе. Например, модель может выдать правильный ответ "клиент вернет кредит", но с вероятностью 0.6. И бизнес, анализируя полученную вероятность, будет понимать, что клиент не настолько надежный (ведь вероятности возврата кредита 60% и 90% совсем разные). Получим неверную картину.

Калибровка вероятностей

ноутбук calibration.ipynb

Калибровка вероятностей

ноутбук calibration.ipynb