

BVD и Random forest

Семинар 12

Как деревья работают с категориальными значениями?

- One hot encoding
- Label encoding
- ***Многозначное разбиение:** Некоторые реализации деревьев поддерживают многозначное разбиение, где каждая категория становится отдельной ветвью

Как деревья работают с NaN?

- **Как в sklearn:** При построении узла алгоритм пробует отправить все пропущенные значения сначала в левого потомка, а затем в правого. Он выбирает то направление, которое дает наибольшее снижение энтропии/дисперсии
- ***Разделение на подмножества:** Если значение признака отсутствует, дерево может разделить объекты на два подмножества: одно для объектов с известным значением, другое — для объектов с NaN.
- ***Использование суррогатных разбиений:** Если основной признак для разбиения содержит NaN, дерево может использовать другой признак (суррогатный) для принятия решения.
- ***Пропуск объектов:** В некоторых реализациях объекты с NaN могут быть пропущены при построении дерева.

Bias-Variance Decomposition (BVD)